

# 少标签情况下的医疗图像分割综述

余子越<sup>1</sup> 罗雨涵<sup>1</sup> 周拓<sup>1</sup>

<sup>1</sup> 南方科技大学 广东省 深圳市 518000

**摘要** 近年来, 基于深度学习的医疗图像分割技术蓬勃发展, 大大提高了疾病诊断率和诊断精度。然而, 用来进行分割任务的训练数据往往需要预先标注的标签, 这是成本高昂且耗时的。因此, 在标注样本有限的情况下进行医疗图像分割已经成为研究的热点。最近几年该领域特别关注了如何通过设计适当的子任务来提高标签的利用率, 以及如何利用半监督, 迁移学习, 自监督学习等方式减小对医疗图像的标签依赖, 从而在仅有少量标签的情况下获得优秀的训练效果。少标签情况下的医疗图像分割首先经历了用于图像分割的深度学习模型, 如卷积网络和 U-Net 等, 对应的示例包括准确率可以达到 66% 的基于神经网络的少标签情况下的黑色素病理分割与检测模型; 随后发展了在少标签情况下通过设计子任务等方式提高模型性能的方法; 该领域未来的研究方向集中在新的监督学习的策略上。

**关键词:** 深度学习 医疗图像分割 标签 自监督 子任务

**中图法分类号** (细化到 3 位数字)

## 1 基于深度学习的医疗图像分割模型

### 1.1 概述

医疗图像分割是一种重要的图像处理技术, 通常用于医学影像学中, 以帮助诊断和治疗。

它涉及将医疗图像中的特定结构、器官或病变区域从其周围环境中分离出来, 以便更精确地分析和理解。如 X 光片下的阴影分析等。医疗图像分割的应用包括但不限于肿瘤检测、器官测量、病变识别和外科手术规划。

这个过程可以是手动的, 也可以是自动的, 但是手动医疗图像分割过程存在诸多弊端, 如非常耗时且劳动密集; 存在一致性和再现性问题; 有着很强的专业知识依赖性; 同时容易存在疲劳和错误问题; 耗费的资源成本高等等。

于是随着医疗资源的日渐紧张, 自动进行准确的医疗图像分割成为了越来越重要的议题。

而在图像分割领域, 深度学习模型在过去的三四十

度学习领域结合是最近数年来最热门的话题。

这里我们先对深度学习模型在图像分割上的进展进行系统性的回顾, 随后着重强调在少标签情况下的医疗图像分割的遇到的问题与进展。

### 1.2 深度学习与图像分割

1998 年出现了对现代网络产生了重大影响的早期卷积网络 (LeNet. Yann LeCun) [1]; 2012 年 Alex Krizhevsky 的 AlexNet 模型使得深度学习在视觉任务中流行起来 [2]。Ross Girshick 2014 年在年 R-CNN 模型的工作将深度学习引入了目标检测 [3]。同年 Jonathan Long 等的工作首次将神经网络用于端到端像素级预测 [4]。Olaf Ronneberger 在 2015 年报告了专为医学图像分割设计, 具有独特的“U”型结构的 U-Net 模型 [5]。同期的 Vijay Badrinarayana 报告了与 U-Net 相似, 但具有不同的上采样策略的 SegNet 模型 [6]。Liang-Chieh Chen 等人则是在 2015 年报告了引入空洞卷积和条件随机场, 用于更精确地处理图

像边缘的 Deeplab 模型[7]。2017 年 Kaiming H 报告了增加了用于像素级分割的分支功能，是 Faster R-CNN 的扩展的 Mask R-CNN 模型[8]。

在图像分割领域过去的发展历程中，最重要且具有代表性的深度模型按照时间顺序为：




Figure 1 timeline

我们选出部分工作详细展开描述：

### 1.2.1 U-Net

U-Net 神经网络是一种卷积神经网络（CNN），由德国的 Olaf Ronneberger 等人于 2015 年提出，主要用于解决图像分割问题。该网络的架构类似于一个“U”字形，因此得名“U-Net”。它由一个收缩路径（编码器，encoder）和一个扩展路径（解码器，decoder）组成，这两条路径在每个阶段都进行卷积和非线性激活操作[5]。

我们通过一个示例理解整个过程：

如下图所示该 U-net 网络有四层，分别对图片进行了 4 次下采样和 4 次上采样。




Fig. 1. U-net architecture (example for 32x32 pixels in the lowest resolution). Each blue box corresponds to a multi-channel feature map. The number of channels is denoted on top of the box. The x-y-size is provided at the lower left edge of the box. White boxes represent copied feature maps. The arrows denote the different operations.

Figure 2 sketch map about U-net

该示例图片从左侧开始进入进行向下操作，经过卷积核进行卷积，通过 ReLU 函数后获得特征通道。随后再次经过卷积核进行卷积，同样通过 ReLU 函数得到特征提取结果，获得第一层处理结果。

随后通过 2X2 池化核，再次通过卷积核提取图像特征，重复该操作，获得足够多的特征层。

结束上述操作后开始进行反向向上操作，先进行反卷积进行矩阵扩大，随后进行上采样，重复这些过程后获得足够的特征层。

最后进行二分类，将图片分为背景和目标两个类别，结束图像分割。

该算法的应用非常广泛，尤其在医学图像中更是如此。在医疗影像的处理中，由于图像包含众多不易分辨清晰的界线，使得传统的图像分割技术无从下手。加之医学图像中的目标结构复杂，单纯依赖图像本身的特征，难以实现精确的目标划分。U-Net 通过创新性的结构设计，实现了图像不同层次特征的融合。这种模型特别强调了在分割过程中对高分辨率特征的利用，以提高边缘的清晰度和分割的准确性。

U-Net 不仅在医学图像分割领域树立了新的标杆，而且推动了更多深度学习算法在精细化处理上的探索。

### 1.2.2 DeepLab

该系列工作一共有 3 篇 [7][9][10], 我们这里着重介绍 DeepLab v1 的工作。

DeepLab v1 的工作结合了深度卷积神经网络 (DCNNs) 和概率图模型 (DenseCRFs) 的方法。通过将 DCNNs 最后一层的响应和完全连接的条件随机场 (CRF) 结合，解决了 DCNNs 做语义分割时精度不够的问题。

该工作基于 VGG16 网络进行了改写，去掉了最后的全连接层以及最后的两个池化层，使用空洞卷积法在不增加计算量的情况下扩大了感受野。

使用的流程图如下：




Figure 3 sketch map about Deeplab

Deeplab 技术的优势明显，它几条非常显著的优势包括：结合了深度可分离卷，能够更高效地进行特征提取，同时保持计算成本相对较低；同时 DeepLab 模型可以进行端到端训练，简化了训练过程，同时允许模型学习复杂的特征表示。

DeepLab 的这些优点使它在医学图像分割、街景理解、机器人视觉等领域都得到了广泛的应用。

同时通过不断的改进和迭代，DeepLab 的各个版本在图像分割任务上取得了领先的性能。

### 1.3 少标签学习

少标签图像是机器学习与计算机视觉领域的重要概念，其中：

“标签”指的是与医疗图像相关联的具体信息，这些信息通常由医学专家提供，用于指明图像中特定结构、器官、病变或其他解剖特征的位置和形状。标签在医学图像分析中扮演着关键角色，尤其是在使用机器学习和深度学习技术进行图像分割时。多标签的数据本身会在模型训练中起到非常大的帮助。

“少标签”意味着有足够多的图像却缺少对应的可用来进行模型训练的相关信息。在这个背景下，模型训练面临着以下挑战：

1. 数据不足：相较于传统的深度学习应用，可用于训练的带标签数据远远不够，这限制了模型学习的深度和广度。
2. 模型训练难度增加：由于缺乏足够的训练样本，模型很难学习到充分泛化的特征表示，增加了过拟合的风险。
3. 对算法存在特殊要求：在少标签的情况下，需要特别设计或选择算法和技术来有效利用有限的标记数据，同时最大化未标记数据的潜在价值。

在传统机器学习中，大量带标签的数据来训练模型是必要的，然而在医学图像分析中，由于专业知识的限制，获得大量带有准确标签的数据成本高昂。在这种情况下，少标签学习策略提供了有效的解决方案。

## 1.4 总结

在医疗图像的自动分割越来越重要，且深度学习在图像分割领域蓬勃发展的情况下，使用深度学习技术解决少标签情况下的医疗图像分割在近年来取得了非常多的进展，具体的解决问题思路在本文第三部分进行了详细叙述，这里不再赘述。

## 2 黑色素瘤病理分割与检测模型

### 2.1 概述

我们建立了一个关于黑色素瘤皮肤病病理照片，基于深度学习的图像分割模型。我们对图像处理，使用水浸算法对图像进行了分割，随后我们使用图像的三种特征：轮廓面积，轮廓与外接圆周长比，最大跨度，构建自监督学习算法进行训练，导入测试集对图像进行识别测试，我们的识别成功率超过了 66%。

### 2.2 算法部分

水浸算法：

水浸算法（Watershed Algorithm）是一种图像处理技术，主要用于图像分割。这种算法将图像视为拓扑地形，其中像素值代表高度。然后，模拟在每个局部最低点（或“最小值”）处注水的过程。在该过程中，随着水位的上升，不同的水池开始合并。于是为了防止这种合并，算法模拟在不同水池之间建立起隔离带（或“分水岭”），从而实现图像的分割。

#### 算法 1 图像处理算法

输入：黑色素瘤病理图像

输出：图像特征与处理结果

1. 导入图像

2. 调节灰度值，二值化处理，水浸算法计算斑痕边界，分割，特征部分读取
3. 输出结果

获得的图像特征部分：（示例）

A1:

1. 轮廓面积: 236.0
2. 周长比: 1.1396875950685794
3. 最大跨度: 22

处理前后对比




Figure 4 Comparison

自监督学习算法：

该算法是无监督学习的一个子类。模型利用未标记的数据来进行自我学习。自监督学习算法的核心思想是从数据本身生成伪标签，并再次使用这些伪标签来训练模型。这种方法特别适用于那些难以获取大量标记数据的场景（如少标签情况下的医疗图像分割）。

#### 算法 2 自监督学习算法

输入：黑色素瘤病理图像特征

输出：识别结果

1. 输入特征值
2. 输入训练集
3. 训练模型
4. 输入测试集并测试

### 2.3 结果与对比

在本次模型训练中，我们使用 python 进行代码书写，我们进行多次训练后，在使用识别图像的三种特征：轮廓面积，轮廓与外接圆周长比，最大跨度作为判断基准，同时在少标签的情况下进行训练，随后输入测试集进行是否为黑色素瘤病变的判断，我们的判断准确率超过了 66%。

### 3 少标签情况下模型性能提升

#### 3.1 概述

少标签情况的含义和造成的困难我们在前文已经提到，这里不再赘述。我们这里给出提升模型性能的思路与方式，并在下文使用具体示例进行解释。

在少标签情况下进行医疗图像分割时，大概的思路包括：

1. 利用现有知识进行扩充学习，例如使用已有的医学图像数据或相关领域的知识，构建预训练模型辅助对应方向的医学成像研究。
2. 提高已有数据的学习效率，可以通过技术手段增强少标签的数据集，使每个样本可以提供更多的信息，例如通过数据增强来生成新的训练样本等。
3. 使用比较灵活的学习策略，采用适应少量标签数据的学习方法，比如半监督学习或自监督学习，这些方法能够从未标记的数据中学习有用信息。
4. 专注于起决定性作用的特征，在医疗图像分割中，关键特征会决定分割质量，可以重点专注于有区分度的特征的学习，以提高模型对少量标签数据的适应性和泛化能力。

5. 模型简化和正则化，使用正则化技术来防止过拟合，这对于在少量数据的训练下可以有效减少误差。

整体而言，关键在于最大化利用可用数据，同时保持对关键医学特征的敏感度，从而进行合理的分割与判断。

在这种思路下，对少标签的情况下进行医疗图像分割时，我们可以考虑使用包括特征提取子任务[11]，辅助分割任务[12]，迁移学习子任务[13]等等方式，减小对医疗图像标签的依赖，获得媲美全监督场景的效果；

#### 3.2 具体例子说明

##### 3.2.1 特征提取子任务

当全监督学习不可行的情况下，比如少标签情况下的医疗图像分割，此时可以设计一个子任务，随后利用未标注数据学习通用特征。例如，可以训练一个自编码器从未标注的医疗图像中学习表示，或者使用对比学习来强化图像中有区分度的特征。

我们将特征提取视为单独的子任务，可以确保后续任务如分割、识别或分类能够基于最优质的特征进行操作。这种方法在资源受限和需要高精度的应用场景（例如少标签情况下的医疗图像分割）中尤为重要。

如 2021 年 Hiroyuki Yamaguchi 等人使用三维卷积自编码器（3D-CAE）从结构性脑成像数据中提取特征，并在不使用诊断标签的情况下应用于精神疾病数据集，展示了无标签特征提取的有效性。

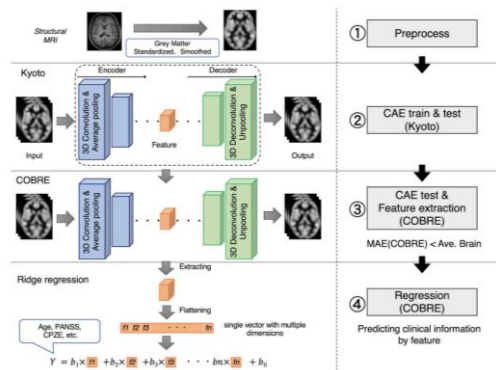


Figure 5 Training diagram




FIGURE 6 | The saliency maps. In our developed 3D-CAE model, the saliency maps of the signals contributing to the prediction of each clinical information were obtained by calculating the gradient of the neural network. 3D-CAE, three-dimensional convolutional autoencoder; PCC, posterior cingulate cortex; MCC, middle cingulate cortex; ACC, anterior cingulate cortex; Temporal\_Mid\_R, right middle temporal gyrus; Temporal\_Mid\_R, right middle temporal gyrus.

Figure 6 3D-CAE Result of recognition

### 3.2.2 辅助分割任务

在少标签的情况下，可以利用可用的少量标注数据率先创建一个辅助任务，例如，分割图像的一部分或某些特定结构，这有助于后续模型对相关特征的识别。

总的来说，辅助分割任务能够增强模型的学习能力，提高分割任务的性能和准确性，特别是在处理少标签情况下的医疗图像分割问题时。

相关的工作如 Shanshan Wang 等人在 NC 上的工作，该模型提出了一种名为 AIDE 的深度学习框架，该框架能够通过一个交叉模型自我标签校正机制，有效地利用低质量的嘈杂训练数据标签来实现准确的图像分割。这个框架通过网络结构优化来应对存在问题的标签数据集，突出了在标注数据有限的情况下，利用未标注的数据来提高医疗图像分割的性能。

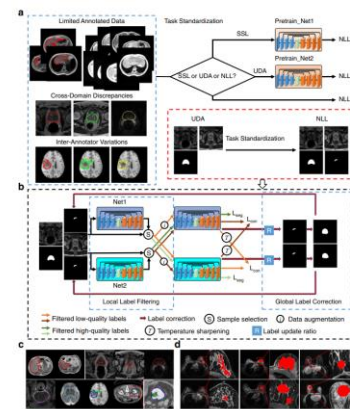


Fig. 1 Overview of AIDE. a The three challenges (semi-supervised learning (SSL), unsupervised domain adaptation (UDA), and noisy label learning (NLL)) that AIDE addresses and the proposed task standardization method. b The overall framework of AIDE, which comprises three major elements: local label filtering, global label correction, and cross-model co-optimization. c Example images of the open datasets. The top left two images are from the CHANs dataset. The top right three images are from the three domains of prostate datasets. The bottom images are from the COBRE datasets, where the first four correspond to the four subtasks and the last one is an enlarged view of the fourth image. Color lines indicate the target regions. d Example images of the breast datasets. From left to right, the three columns correspond to the images collected from the three medical centers. Red color regions show the breast tumors.

Figure 7 overview of AIDE

### 3.2.3 迁移学习子任务

在某一些专业领域的训练集标签较少的情况下，也可以从其他领域或相关医学图像分割任务中分享与迁移知识。例如，可以在大型公共数据集上预训练模型，然后在目标任务上进行微调。

实行预训练的迁移学习子任务方式在处理特定子任务时提供了加速学习、提高性能、增强泛化能力、节约资源和增加应用灵活性的好处，尤其适用于数据有限或需要高效计算的情况。

Riaan Zoetmulder 等人 2022 年的工作证明了该方向的可行性。该研究团队使用不同的源任务和域组合来评估基于迁移学习的医学分割任务的性能，他们发现预训练在同一领域的分割任务对目标任务的分割精度有直接影响。他们先行进行在分类、分割以及自监督任务上的卷积神经网络（CNN）的预训练，然后在特定的 T1 脑部 MRI 分割任务上进行微调，结果表明，同领域的预训练有助于提高分割精度。



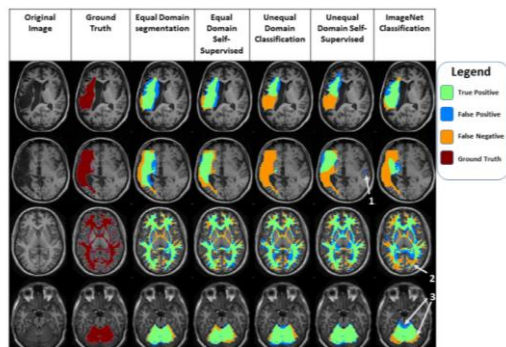


Figure 8 Pre-training effect diagram

### 3.3 总结

在进行少标签情况下进行医疗图像分割时，可以通过利用现有知识进行扩充学习，同时提高已有数据的学习效率，以及使用比较灵活的学习策略，或者专注于起决定性作用的特征等思路完成模型效率的提升。

这些思路都经过了对应模型的检验，但是依旧在某些特定的情况下存在问题。

### 结束语

在少标签情况下的医疗图像分割技术一直以来都是一项具有挑战性的任务，因为获取大量精确的医疗图像标签非常困难。目前多种技术，包括半监督学习、迁移学习、自监督学习和数据增强有望克服目前的困难。这些方法充分利用了有限的标签数据，一方面可以通过引入无标签数据来提高分割模型的性能，另一方面也可以通过设计辅助任务或使用预训练的网络，在不牺牲准确度的前提下减少对大量标注数据的依赖。这些进展为临床应用中的自动化医疗图像分析开辟了新的可能性。

在未来，我们预计在少标签情况下医疗图像分割技术的发展趋势可能会聚焦于几个关键领域：深化迁移学习和元学习策略[14][15]等。这些方法可更有效地利用无标签数据，同时处理特征学习和图像分割。此外，生成对抗网络（GAN）和对比学习[16][17]等技术可能也会在未来的图像分割任务中发挥更大作用，特别是在数据稀缺的医疗领域。随着计算能力的提升和算法的进步，我们预期这些技术将解决医疗图像分割中的少标签问题。

### 致谢

致谢余子越(我本人!)，周拓，罗雨涵。

以及亲爱的聂秋实学长（3年前听过学长的Java课，印象非常深刻!!）

### 参考文献

- [1] Lecun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278 - 2324. <https://doi.org/10.1109/5.726791>
- [2] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2017). ImageNet classification with deep convolutional neural networks. *Communications of the ACM*, 60(6), 84 - 90. <https://doi.org/10.1145/3065386>
- [3] Girshick, R., Donahue, J., Darrell, T., & Malik, J. (2014). Rich feature hierarchies for accurate object detection and semantic segmentation (arXiv:1311.2524). [arXiv. http://arxiv.org/abs/1311.2524](http://arxiv.org/abs/1311.2524)

- [4] Long, J., Shelhamer, E., & Darrell, T. (2015). Fully Convolutional Networks for Semantic Segmentation (arXiv:1411.4038). arXiv. <http://arxiv.org/abs/1411.4038>
- [5] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation (arXiv:1505.04597). arXiv. <http://arxiv.org/abs/1505.04597>
- [6] Badrinarayanan, V., Kendall, A., & Cipolla, R. (2016). SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation (arXiv:1511.00561). arXiv. <http://arxiv.org/abs/1511.00561>
- [7] Chen, L.-C., Papandreou, G., Kokkinos, I., Murphy, K., & Yuille, A. L. (2016). Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs (arXiv:1412.7062). arXiv. <http://arxiv.org/abs/1412.7062>
- [8] He, K., Gkioxari, G., Dollár, P., & Girshick, R. (2018). Mask R-CNN (arXiv:1703.06870). arXiv. <http://arxiv.org/abs/1703.06870>
- [9] Chen, L.-C., Papandreou, G., Kokkinos, I., Murphy, K., & Yuille, A. L. (2017). DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs (arXiv:1606.00915). arXiv. <http://arxiv.org/abs/1606.00915>
- [10] Chen, L.-C., Papandreou, G., Schroff, F., & Adam, H. (2017). Rethinking Atrous Convolution for Semantic Image Segmentation (arXiv:1706.05587). arXiv. <http://arxiv.org/abs/1706.05587>
- [11] Yamaguchi, H., Hashimoto, Y., Sugihara, G., Miyata, J., Murai, T., Takahashi, H., Honda, M., Hishimoto, A., & Yamashita, Y. (2021). Three-Dimensional Convolutional Autoencoder Extracts Features of Structural Brain Images With a “Diagnostic Label-Free” Approach: Application to Schizophrenia Datasets. *Frontiers in Neuroscience*, 15, 652987. <https://doi.org/10.3389/fnins.2021.652987>
- [12] Wang, S., Li, C., Wang, R., Liu, Z., Wang, M., Tan, H., Wu, Y., Liu, X., Sun, H., Yang, R., Liu, X., Chen, J., Zhou, H., Ben Ayed, I., & Zheng, H. (2021). Annotation-efficient deep learning for automatic medical image segmentation. *Nature Communications*, 12(1), 5915. <https://doi.org/10.1038/s41467-021-26216-9>
- [13] Zoetmulder, R., Gavves, E., Caan, M., & Marquering, H. (2022). Domain- and task-specific transfer learning for medical segmentation tasks. *Computer Methods and Programs in Biomedicine*, 214, 106539. <https://doi.org/10.1016/j.cmpb.2021.106539>
- [14] Peng, L., Liang, H., Luo, G., Li, T., & Sun, J. (2022). Rethinking Transfer Learning for Medical Image Classification (arXiv:2106.05152). arXiv. <http://arxiv.org/abs/2106.05152>
- [15] Wei, Q., Yu, L., Li, X., Shao, W., Xie, C., Xing, L., & Zhou, Y. (2023). Consistency-guided Meta-Learning for Bootstrapping Semi-Supervised Medical Image Segmentation (arXiv:2307.11604). arXiv. <http://arxiv.org/abs/2307.11604>
- [16] Jeong, J. J., Tariq, A., Adejumo, T., Trivedi, H., Gichoya, J. W., & Banerjee, I. (2022). Systematic Review of Generative Adversarial Networks (GANs) for Medical Image Classification and Segmentation. *Journal of Digital Imaging*, 35(2), 137–152. <https://doi.org/10.1007/s10278-021-00556-w>
- [17] Xun, S., Li, D., Zhu, H., Chen, M., Wang, J., Li, J., Chen, M., Wu, B., Zhang, H., Chai, X., Jiang, Z., Zhang, Y., & Huang, P. (2022). Generative adversarial networks in medical image segmentation: A review. *Computers in Biology and Medicine*, 140, 105063. <https://doi.org/10.1016/j.combiomed.2021.105063>





Ziyue Yu , born in Shanxi province, undergraduate student, His/Her main research interests include soft robotics and turbulent .



Tuo Zhou , born in Hunan province, undergraduate student, His main research interests include soft robotics and fluid mechanics .



Yuhua Luo , born in Sichuan province, undergraduate student. Her main research interests include reinforcement learning and combination optimization.