



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

本科生毕业论文

题 目： 基于临床特征融合注意力网络的
 白内障分级模型研究

姓 名： 赵宇航

学 号： 11910711

系 别： 计算机科学与工程系

专 业： 计算机科学与技术

指导教师： 刘 江

年 月 日

诚信承诺书

1. 本人郑重承诺所呈交的毕业设计（论文），是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料均真实可靠。
2. 除文中已经注明引用的内容外，本论文不包含任何其他人或集体已经发表或撰写过的作品或成果。对本论文的研究作出重要贡献的个人和集体，均已在文中以明确的方式标明。
3. 本人承诺在毕业论文（设计）选题和研究内容过程中没有抄袭他人研究成果和伪造相关数据等行为。
4. 在毕业论文（设计）中对侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：

_____年____月____日

基于临床特征融合注意力网络的 白内障分级模型研究

赵宇航

(计算机科学与工程系 指导教师：刘江)

[摘要]：白内障是导致视觉损伤与失明的主要疾病。目前已有一些研究将神经网络模型应用于白内障自动分级工作，但大多研究关注如何提高白内障的分类性能，对于网络的可解释性（可理解性）方面关注较少。因此，本文提出一种临床特征融合注意力网络的白内障分级模型 CFINet 来解决核性白内障分类问题。在提出的网络模型中，本文设计了临床特征融合注意力模块，其通过动态调整特征图不同区域的权重从而使网络模型关注重要的病理区域。本文在临床 AS-OCT 影像数据集与公开 LAG 数据集上分别进行了实验，实验结果表明，本文模型的分类性能优于其他先进注意力机制网络模型。例如，在临床 AS-OCT 影像数据集上，本文模型的准确率达到了 92.161%，相较于其他先进注意力机制能够提高 1-2%。此外，本文还使用了可视化方法来展示神经网络对于重要的病理区域的关注，提高了本文模型在决策过程中的可解释性。

[关键词]：核性白内障分类；眼前节光学相干断层成像；临床特征融合注意力模块；可解释性

[ABSTRACT]: Cataract is a major disease that causes visual impairment and blindness. Some studies have applied neural network models to automatic cataract grading work, but most of them focus on how to improve the classification performance of cataract, with less attention to the interpretability(intelligibility) aspect of the network. Therefore, this paper proposes a clinical features integrated attention network(CFINet) to solve the nuclear cataract classification problem. In the proposed network model, we designed a clinical feature integrated attention module, which makes the network model focus on important pathological regions by dynamically adjusting the weight of different regions in the feature map. In this paper, experiments are conducted on clinical AS-OCT image dataset and public LAG dataset respectively, and the experimental results show that the model in this paper has better classification performance compared with other advanced attention network models. The accuracy of this model reaches 92.161% on the clinical AS-OCT image dataset, which is 1-2% better than other advanced attention mechanisms. In addition, this paper also uses a visualization method to demonstrate the focus of neural networks on important pathological areas, which improves the comprehensibility of the model in the decision-making process.

[Keywords]: nuclear cataract classification; AS-OCT; clinical features integrated attention model; interpretability

目录

1. 引言.....	1
2. 临床特征融合注意力网络模型.....	3
2.1 临床特征融合注意力模块.....	3
2.2 网络模型.....	4
3. 数据集介绍.....	4
3.1 临床 AS-OCT 影像数据集.....	4
3.2 LAG 数据集.....	5
4. 实验设置与结果分析.....	5
4.1 评价标准.....	5
4.2 实验设置.....	6
4.3 基准模型.....	6
4.4 结果分析.....	6
4.5 可视化结果分析.....	7
4.5.1 分组权重可视化结果.....	7
4.5.2 基于类激活映射方法的可视化结果.....	8
5. 结束语.....	9
参考文献.....	11
致谢.....	13

1. 引言

《2021-2022 年度全球眼健康调研报告》显示，世界上大约有 2.85 亿人视力受损，其中有 3900 万人失明，而 51% 的失明病例和 33% 的视力损害病例是由白内障引起，白内障已成为全球第一的致盲性眼科疾病。根据中华医学会眼科学分会统计，我国 60 至 89 岁人群的白内障发病率大约为 80%，90 岁以上人群的白内障发病率甚至达 90% 以上。50 岁以上人群视力障碍比例高达 30%，主要原因就是白内障。

白内障在临床上表现为眼睛的晶状体出现混浊，因此导致视力受损乃至失明。根据晶状体的混浊部位，白内障从内而外可分为三种类型：核性白内障，皮质性白内障，以及后囊性白内障^[1]。其中，核性白内障是一种常见的白内障类型，其在临床上的表现为晶状体的核性部分产生混浊，本文所研究的白内障分级模型即针对核性白内障。根据 LOCS III（Lens Opacities Classification System III，晶状体混浊分类系统）^[2]以及临床诊断需要，核性白内障可分为三种级别：正常，轻度以及重度^[3]。正常指晶状体核性区域未出现混浊；轻度指晶状体核性区域出现不明显混浊，对应 LOCS III 中的一级和二级；重度指晶状体核性区域出现明显混浊，对应 LOCS III 中的三级及以上级别。

受我国老龄化影响，白内障患者人数逐年增加，导致了如今医患数量的不均衡。同时，在诊断时，医生通常基于自身的临床经验来判断白内障级别，这种诊断方法主观性较强且与医生本身诊断水平有关，不能保证其准确性。所以，开发计算机辅助诊断白内障技术来提高诊断的效率与准确性是有必要的。

近年来，已有一些研究将神经网络模型应用于白内障自动分级工作中。Cao 等人采用深度分割网络对 AS-OCT 图像进行分割，得到了图像的核性、皮质和囊性区域^[4]，为三种类型白内障的分类工作打下了基础。刘振宇等人使用卷积神经网络来提取裂隙灯图像的特征，在核性白内障分级中获得了不错的效果^[5]；李建强等人使用深度学习方法来提取眼底图像的特征进行白内障分类^[6]；Xu 等人设计了一种在眼底图像上的全局-局部特征表示模型来提高白内障的分级性能^[7]。对于白内障的分类工作，如今大多研究关注如何提高白内障的分类性能，但对于神经网络模型的可解释性方面关注较少。

相较于上文提到的裂隙灯图像和眼底图像，AS-OCT（Anterior Segment Optical Coherence Tomography，眼前节光学相干断层成像）对于晶状体结构的获取更加清晰完整，更适合不同类型白内障的分类。文献^[8, 9]在 AS-OCT 影像下使用斯皮尔曼相关

系数方法分析了像素均值与核性白内障严重程度之间相关性，结果显示两者存在较强相关性。因此，在网络中可以选择平均池化的方式来凸显像素均值这一关键特征。有临床研究指出核性白内障患者晶状体核性区域的中间与下半部分混浊程度比上半部分更明显^[10]。因此，注意力网络需对空间维度，尤其是对纵向的病理分布给予更多关注，使网络能够将更多的注意力给到重要的病理区域。

注意力机制(attention mechanism)在加入神经网络后，能够提高网络模型在处理医学影像任务中的效果^[11]，同时这也是一种提高网络可解释性的方式。挤压激励注意力机制(squeeze-and-excitation attention mechanism)是一种被广泛运用的注意力机制，在解决计算机视觉问题中有很好的效果^[12]。但它是一种通道注意力机制，根据上文提到的核性白内障患者晶状体核性区域特点，我们更倾向于关注空间维度。坐标注意力(coordinate attention)是一种通道注意力与空间注意力结合的注意力机制，它能充分的利用空间信息^[13]。但它将纵向维度与横向维度等价处理，对空域的处理没有针对性，而我们更想对纵向维度给予更多的关注，所以其对于解决我们的问题也有一定的不足。空间分组增强(Spatial Group-wise Enhance)模块是一种通过对通道分组，达到凸显其特征语义的空间注意力机制^[14]。虽然它是针对空间的注意力机制，但我们的图片并没有特别明显的语义特征，所以并不适用于我们的问题。但它的分组思想可以借鉴使用来达到我们想要更加关注纵向维度的目的。




图 1 临床特征融合注意力模块 (CFI)

根据白内障临床特征与注意力网络特点，本文提出是否可以将像素均值转化为特征图的特征表示，并将表示图像下半部分的特征放大，以此来提升核性白内障的分类效果并提高网络的可解释性。为此，本文提出了一个临床特征融合注意力网络 (Clinical Features Integrated Attention Network, CFINet) 来对核性白内障进行自动分类。在提出的 CFINet 中，插入一个临床特征融合注意力模型 (Clinical Features Integrated Attention Model, CFI)。如图 1 所示，该模型对输入特征的纵向维度进行

分组并在横向维度进行平均池化操作,以获得其在每一纵向维度上的像素均值特征表达,之后为每一个特征生成重要性系数,并进行归一化与激活函数处理,从而实现特征图重要信息的放大。

本文在两个数据集上进行实验,以证明本文模型的性能高于已有注意力网络。为了更直观的了解模型的决策过程,本文使用类激活映射可视化方法来展示特征的权重分布。

2. 临床特征融合注意力网络框架

2.1 临床特征融合注意力模块

图 2 所示为该临床特征融合注意力网络结构图。对于任一卷积特征图 $\mathbf{X} = [x_1, x_2, \dots, x_c] \in \mathbf{R}^{N \times C \times H \times W}$ (其中, N 表示批大小, C 表示通道数, H 和 W 表示特征图的高和宽)。我们考虑将其沿 H 维度划分为 G 组,目的是凸显出那些表示图像下半部分的组的特征。在上文白内障临床特征部分提到过可选择平均池化的方式来凸显像素均值这一关键特征,所以首先要对 W 维度进行平均池化操作,以获得其在每一 H 维度上的特征表达:

$$\mathbf{g} = \frac{1}{W} \sum_{0 \leq i \leq W} \mathbf{x}_c(h, i) \quad (1)$$

同时要利用该特征表达为每一个特征生成相应的重要性系数,这一步可以使用简单的点乘来实现:

$$c_i = \mathbf{g} \cdot \mathbf{x}_i \quad (2)$$

为了防止不同组之间系数大小有偏差,我们在 W 维度上对 c 进行归一化处理:

$$\hat{c}_i = \frac{c_i - \mu_c}{\sigma_c + \epsilon}, \quad \mu_c = \frac{1}{W} \sum_j^W c_j, \quad \sigma_c^2 = \frac{1}{W} \sum_j^W (c_j - \mu_c)^2 \quad (3)$$

其中 ϵ 是为了数值稳定性而添加的常数。简单地归一化可能会改变图层可以表示的内容,为了确保插入网络中的转换可以表示恒等转换,引入一对参数 β 、 γ 来对归一化值进行缩放和移位:

$$a_i = \gamma \hat{c}_i + \beta \quad (4)$$

为了获得增强的特征向量 \hat{x}_i , 原始 x_i 被生成的重要性系数 a_i 通过 sigmoid 函数作为门控单元在空间上缩放:

$$\hat{x}_i = \mathbf{x}_i \cdot \sigma(a_i) \quad (5)$$

最后,所有增强的特征组成了特征组 $\hat{\mathbf{X}} = [\hat{x}_1, \hat{x}_2, \dots, \hat{x}_c] \in \mathbf{R}^{N \times C \times H \times W}$ 。

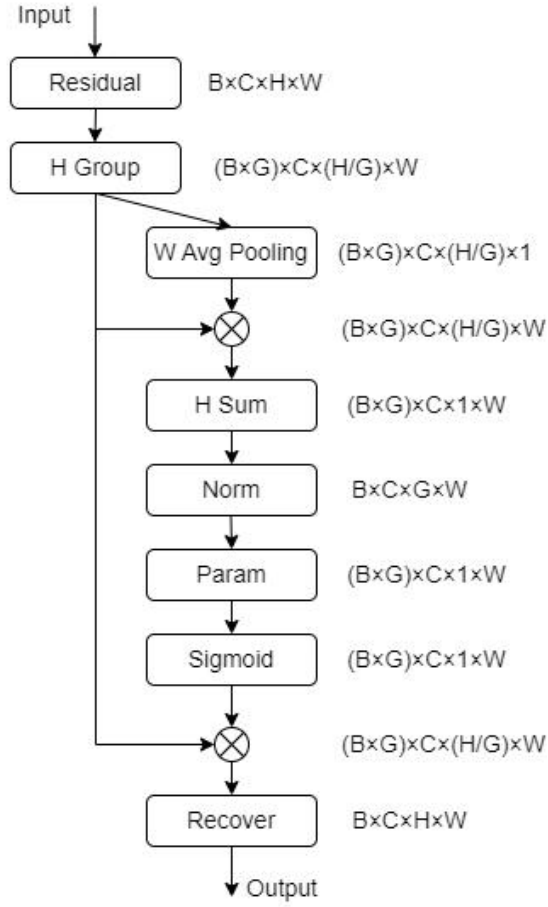


图 2 临床特征融合注意力模块（CFI）结构图

2.2 网络模型

本文网络模型以 ResNet^[15]（residual convolutional neural network，残差卷积神经网络）作为网络骨架，原因在于许多其他的注意力网络都使用它作为主干网络，且它在分类任务中可以取得很好的结果，可以更好的验证本文网络模型的性能。本文将提出的临床特征融合注意力模块插入到残差模块中构成残差临床特征融合注意力模块，本文的网络框架 CFInet 是由多个残差临床特征融合注意力模块组合而成的。

3. 数据集介绍

3.1 临床 AS-OCT 影像数据集

临床 AS-OCT 影像数据集来源于某一三甲医院，由日本 Tomey 公司生产的 CASIA2 设备进行采集。数据集包括 530 名受试者以及 839 只眼睛，其中左眼 428 只，右眼 411 只，经专业医生筛选后得到 15884 张可用的 AS-OCT 影像。目前还没有基于

AS-OCT 图像的白内障分级标准,由于受试者同时拍摄了 AS-OCT 图像与裂隙灯图像,所以由专业医生基于 LOC III 分级标准给出裂隙灯图像下的白内障级别并进行映射,以得到每张 AS-OCT 图像的白内障严重级别标签。根据临床经验以及数据规律,同一个受试者的两只眼睛白内障严重级别相近,所以本文以受试者为基本单位对数据进行随机拆分,以 6: 2: 2 的比例分为训练集,验证集以及测试集。表 1 为训练集、验证集和测试集的三种严重程度的核性白内障的 AS-OCT 影像数量分布。

表 1 三种核性白内障严重级别数量分布表

数据集	正常	轻度	重度
训练集	1004	2872	5518
验证集	229	569	2302
测试集	345	1305	1740
总计	1578	4746	9560

3.2 LAG 数据集

LAG 数据集是参考文献^[16]Li 等人为检测青光眼建立的眼底图像数据集。选择该数据集的原因在于,青光眼患者的一大特征就是视杯面积与视盘面积之比一般较大^[17],也就是说在“高”维度上的像素分布对于在眼底图像上诊断青光眼也是重要的一点。实验将数据随机分为训练集,验证集和测试集,其中训练集有图片 2911 张,验证集有图片 972 张,测试集有图片 971 张。表 2 为训练集、验证集和测试集的两种眼底图像数量分布。

表 2 两种眼底图像数量分布表

数据集	正常	患病
训练集	1885	1026
验证集	629	342
测试集	629	343
总计	3143	1711

4. 实验设置与结果分析

4.1 评价标准

根据参考文献^[18, 19, 20], 本文采用 ACC (Accuracy, 准确率)、PR (Precision Rate, 精确率)、Sen (Sensitivity, 召回率)、F1 指标以及 Kappa 系数五种评价标准来衡量本文方法的性能。其中, 准确率表示方法预测出的正确数目占总数的比例, 精确率表示实际正例数目占被分为正例的比例; 召回率表示分类器中判定为真的正例占总正例的比率; F1 指标是精确率和召回率的调和平均值。准确率、精确率、召回率和 F1 评价指标可以通过以下公式表示:

$$ACC = \frac{TP+TN}{TP+FN+TN+FP} \quad (6)$$

$$PR = \frac{TP}{TP+FP} \quad (7)$$

$$Sen = \frac{TP}{TP+FN} \quad (8)$$

$$F1 = \frac{2 \times PR \times RR}{PR+RR} \quad (9)$$

其中, TP 表示真阳性, TN 表示真阴性, FP 表示假阳性, FN 表示假阴性。

4.2 实验设置

实验使用 PyTorch、scikit-learn 等软件包来实现模型搭建。深度学习模型采用 SGD (Stochastic Gradient Descent, 随机梯度下降优化器) 作为优化器。epochs (训练周期) 设置为 150, batch size (批量大小) 设置为 32、LR (Learning Rate, 初始化学习率) 设置为 0.0025, 当 epochs 小于 10 时, 每个 epochs 学习率增加十分之一; 当 epochs 大于 100 时, 每个 epochs 学习率缩小 10 倍。本实验将所有影像的高和宽都缩放为 224*224, 作为神经网络模型的输入。实验硬件环境配置为 1 张 Nvidia Titan GPU, Ubuntu 操作系统, DDR 12 GB 内存。

4.3 基准模型

为了验证本文模型的有效性, 实验选择以下先进注意力模型作为基准注意力模型进行对比: SE (挤压激励注意力)、CA (坐标注意力)、SGE (空间分组增强)、SRM^[21] (风格校准模块) 和 BAM^[22] (瓶颈注意力组件)。其中既有通道注意力模型、空间注意力模型, 也有通道与空间相结合的注意力模型, 可以更全面的验证本文模型的性能。

4.4 结果分析

实验采用 Resnet18 作为网络骨架，将各种注意力模型嵌入其中进行分类任务。表 3 展示了本文的注意力模块 CFI 与其他注意力模块在临床 AS-OCT 影像数据集上的分类效果对比。

表 3 不同注意力机制在临床 AS-OCT 影像数据集上的分类结果对比表

方法	ACC	PR	Sen	F1	Kappa
Resnet18	88.557	86.882	91.356	88.612	74.823
Resnet18+SE	89.516	86.315	93.883	89.075	77.100
Resnet18+CA	91.484	88.562	94.060	90.697	80.672
Resnet18+SGE	89.874	87.563	93.321	89.781	77.958
Resnet18+SRM	90.968	88.469	94.093	90.639	79.724
Resnet18+BAM	90.097	87.872	94.630	90.138	78.395
Resnet18+CFI	92.161	87.981	94.232	90.712	82.092

注：加粗数字表示最优结果。

可以看到，本文模块在 ACC、F1、Kappa 三个评价标准上的效果都可以达到最好，分别为 92.161%，90.712%，82.092%，且在 ACC 评价标准中，相比其他模块能够提高 1-2%；在 PR 和 Sen 标准中，SRM 与 BAM 取得了最好的效果，但 CFI 模块与其相差很小。

表 4 列出了 CFI 模块与其他模块在 LAG 数据集上的实验结果对比，可以看到 CFI 模块在五个评价标准中都取得了最高的成绩，分别为 95.057%，94.933%，94.183%，94.539%，89.079%，证明该模型具有很好的泛化能力。

表 4 不同注意力机制在 LAG 数据集上的分类结果对比表

方法	ACC	PR	Sen	F1	Kappa
Resnet18	94.342	93.991	93.573	93.776	87.553
Resnet18+SE	93.827	93.195	93.308	93.251	86.502
Resnet18+CA	94.753	94.505	93.958	94.221	88.443
Resnet18+SGE	93.827	93.063	93.507	93.277	86.555
Resnet18+SRM	94.342	93.559	94.170	93.849	87.700
Resnet18+BAM	93.210	92.614	92.500	92.556	85.113
Resnet18+CFI	95.057	94.933	94.183	94.539	89.079

注：加粗数字表示最优结果。

4.5 可视化结果分析

4.5.1 分组权重可视化

本文统计了在不同深度的 CFI 模块中,不同组权重的分布。由于在实验中发现当组数为 7 时,本文模型可以得到最好的结果,所以在分组权重分析中使用组数为 7 的模型。如图 3 所示,分别展示出了 layer1.1、layer2.1、layer3.1 和 layer4.1 这 4 层中对于不同组的权重折线图。因分组按照图像纵向维度进行,可以认为 0-2 组代表图像上半部分,3 组代表图像中间部分,而 4-6 组代表图像下半部分。之前提到,白内障的病理区域大多表现在图像的中间以及下半部分。由图可以看出,CFI 模块在每一层都倾向于赋予图像下半部分相对更大的权重值,尤其对于第 4 组,基本所有层中都将最高的权重赋给了它。而随着网络的加深,网络模型对于图像的病理区域更为关注,比如在 layer4.1,给予了 3-6 组更大的权重值。以上结果说明了本文提出的 CFI 模块能够提高对白内障病理区域的关注,以此来提高分类效果以及提升模型决策过程的可理解性。

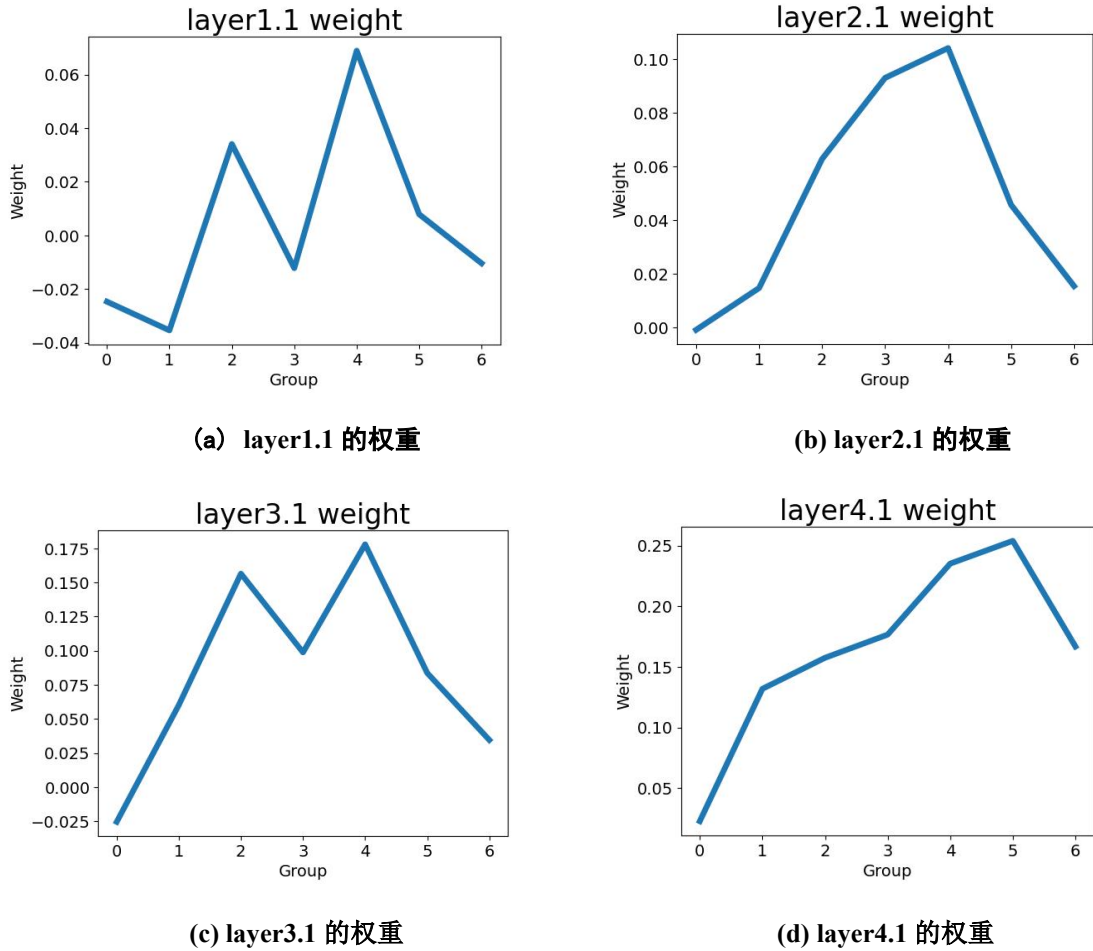


图 3 CFINet 分组权重分布折线图

4.5.2 基于类激活映射方法的可视化

本文使用 CAM (class activation mapping, 类激活映射)^[23, 24] 可视化方法来展示神经网络在推理过程中对图片的重点关注区域。如图 4 所示, 为 CFINet 和其他注意力网络模型具有代表性的三种级别核性白内障图片的可视化类激活图。其中第一行是一张正常的 AS-OCT 图像以及其对应的各种注意力网络模型类激活图; 第二行是患有轻度核性白内障患者的 AS-OCT 图像以及其对应的各种注意力网络模型类激活图; 而第三行则代表患有重度核性白内障患者的 AS-OCT 图像以及其对应的各种注意力网络模型类激活图。第一列是三种级别核性白内障的 AS-OCT 图片, 而第二列到第七列分别代表 SE、CA、SGE、SRM、BAM、CFI 六种注意力网络模型所对应的类激活图。可以看出, 对于正常的 AS-OCT 图像, 由于像素分布比较均匀, 六种注意力网络模型都关注整个核性区域。而对于患病的 AS-OCT 图像, 本文的 CFINet 相比于其他的注意力网络模型能够更多的关注到图像的病理区域, 符合白内障的临床特征, 也解释了本文模型性能高于其他模型的原因。

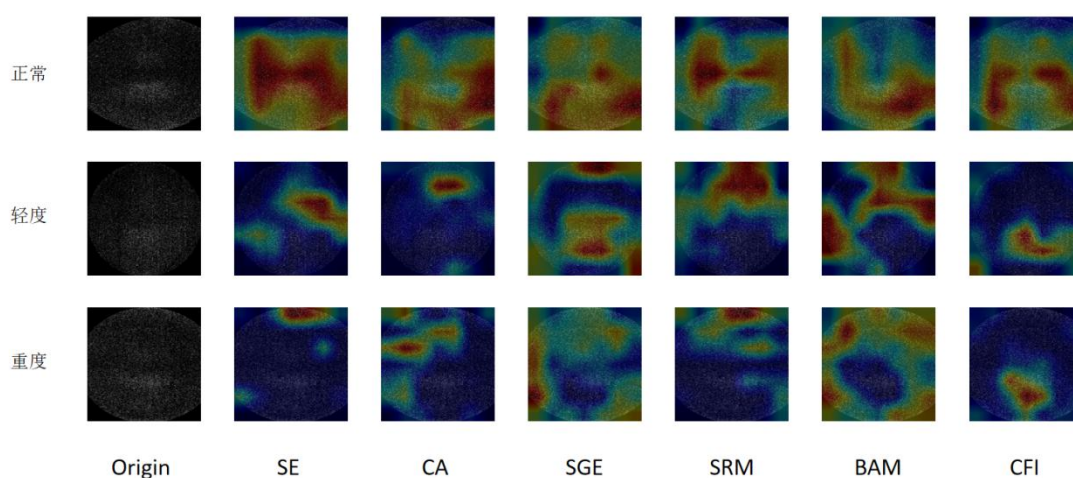


图 4 CFINet 与其他注意力网络模型的可视化类激活图

5. 结束语

本文将白内障临床特征融入模型设计, 根据影像像素特征以及浑浊分布设计出一种临床特征融合注意力网络的白内障分类模型 (CFINet), 实现了在 AS-OCT 影像下核性白内障的自动分级。本文模型在 AS-OCT 影像数据集上的测试准确率达到了 92.161%, 可以高出对比方法 1-2%。可视化结果显示, 本文模型能够更加关注核性

白内障关键病理部位，解释了取得好结果的原因。在 LAG 数据集上的实验证明，本文模型具有良好的泛化能力，对于解决其他眼病的分类问题有一定的参考价值。

然而，如何将更多的临床特征融入到注意力网络设计中来提升模型分类效果，是接下来需要解决的问题。对于可解释性方面的理论证明，也需要进一步进行研究。同时，如何设计更轻量级的网络，以能够将模型部署到眼科医疗系统中，也是需要继续努力探索的问题。

参考文献

- [1] GALI HELENA E, SELLA, RUTI, AFSHARI, NATALIE A. Cataract grading systems: a review of past and present[J]. Current opinion in ophthalmology, 2019, 30(1):13-18.
- [2] L T CHYLACK, J K WOLFE, D M SINGER, M C LESKE, M A BULLIMORE, I L BAILEY, J FRIEND, D MCCARTHY, S Y WU. The Lens Opacities Classification System III[J]. Archives of Ophthalmology, 1993 Jun;111(6):831-6.
- [3] OZGOKCE M, BATUR M, ALPASLAN M, et al. A comparative evaluation of cataract classifications based on shear-wave elastography and B-mode ultrasound findings[J]. Journal of Ultrasound, 2019, 22(4):447-45.
- [4] Cao Guiping,Zhao Wei,Higashita Risa,Liu Jiang,Chen Wan,Yuan Jin,Zhang Yubing,Yang Ming. An Efficient Lens Structures Segmentation Method on AS-OCT Images[J]. 42ND ANNUAL INTERNATIONAL CONFERENCES OF THE IEEE ENGINEERING IN MEDICINE AND BIOLOGY SOCIETY: ENABLING INNOVATIVE TECHNOLOGIES FOR GLOBAL HEALTHCARE EMBC'20,2020.
- [5] 刘振宇, 宋建聪. 基于深度学习的白内障自动诊断方法研究 [J]. 微处理机, 2019, 40(03):48-52.
- [6] 李建强, 张苓琳, 张莉, 杨吉江, 王青. 基于深度学习的白内障识别与分级 [J]. 第二军医大学学报, 2018, 39(08):878-885. DOI:10.16781/j.0258-879x.2018.08.0878.
- [7] Xu X, Zhang L, Li J, et al. A Hybrid Global-Local Representation CNN Model for Automatic Cataract Grading[J]. IEEE Journal of Biomedical and Health Informatics, 2020,24(2):556-567.
- [8] Wong A L, Leung K S, Weinreb R N, et al. Quantitative assessment of lens opacities with anterior segment optical coherence tomography[J]. British Journal of Ophthalmology,2009, 93(1):61-65.
- [9] Makhotkina, Natalia, Y, et al. Comparability of subjective and objective measurements of nuclear density in cataract patients[J]. Acta Ophthalmologica, 2018.
- [10] Thylefors B, Chylack L T, Konyama K, et al. A simplified cataract grading system The WHO Cataract Grading Group[J]. Ophthalmic Epidemiol, 2002, 9(2):83-95.
- [11] 陈朝一, 许波, 吴英, 吴凯文. 医学图像处理中的注意力机制研究综述[J]. 计算机工程与应用, 2022, 58(05):23-33.
- [12] Hu J, Shen L, Sun G, et al. Squeeze-and-Excitation Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, PP(99).
- [13] Hou Q, Zhou D, Feng J. Coordinate attention for efficient mobile network design[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 13713-13722.
- [14] Xiang Li, Xiaolin Hu, Jian Yang. Spatial Group-wise Enhance: Improving Semantic Feature Learning in Convolutional Networks.[J]. CoRR, 2019, abs/1905.09646.
- [15] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun 0001. Deep Residual Learning for Image

- Recognition.[J]. CoRR, 2015,abs/1512.03385.
- [16] Li Liu et al. A Large-Scale Database and a CNN Model for Attention-Based Glaucoma Detection.[J]. IEEE transactions on medical imaging, 2020, 39(2) : 413-424.
- [17] 徐志京, 汪毅. 青光眼眼底图像的迁移学习分类方法 [J]. 计算机工程与应用, 2021, 57(03) : 144-149.
- [18] 章晓庆, 方建生, 肖尊杰, 陈浜, Risa HIGASHITA, 陈婉, 袁进, 刘江. 基于眼前节相干光断层扫描成像的核性白内障分类算法[J]. 计算机科学, 2022, 49(03) : 204-210.
- [19] Zhang X ,Hu Y ,Xiao Z , et al. Machine Learning for Cataract Classification/Grading on Ophthalmic Imaging Modalities: A Survey[J]. Machine Intelligence Research, 2022, 19(03):184-208.
- [20] Cao L, Li H, Zhang Y, et al. Hierarchical method for cataract grading based on retinal images using improved Haar wavelet[J]. Information Fusion, 2019
- [21] Lee H J, Kim H E, Nam H. SRM: A style-based recalibration module for convolutional neural networks[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 1854-1862.
- [22] Park J, Woo S, Lee J Y, et al. A simple and light-weight attention module for convolutional neural networks[J]. International Journal of Computer Vision, 2020, 128(4): 783-798.
- [23] Zhou B, Khosla A, Lapedriza A, et al. Learning Deep Features for Discriminative Localization[J]. CVPR, 2016.
- [24] 司念文. 面向图像识别的深度学习可视化解释技术研究[D]. 战略支援部队信息工程大学, 2021. DOI:10.27188/d.cnki.gzjxu.2021.000012.

致谢

时光荏苒，四年转瞬即逝。我与南科会于 2019 年初秋，别于 2023 年盛夏，回忆四年，皆为美好。

感谢在生活与学习中给予我帮助的导师刘江教授。我们一起庆祝节日，一起爬山，一起玩耍，即使远在他乡，刘老师也给了我家一般的温暖。在遇到学习问题，学术困难时，刘老师也总会耐心的给予最全面的帮助。也要感谢实验室的章晓庆师兄，师兄重视培养我的科研思维，对于论文的选题和写作都给予了非常大的帮助，同时师兄对于科研的认真与坚持也是我在学术生涯中需要一直学习的。

感谢我的父母，一直默默的在我身后支持着我的求学生涯。你们说：“我俩好好工作，你好好学习，一家三口一起努力！”你们说：“我们对你现在做的事情了解不多，但一定会尊重和支持你的决定！”你们是我成长路上最温暖的港湾！我为有这样一个美满的家庭而感到十分的幸运与骄傲。

感谢朋友们，感谢易哥，涛哥，轶群哥，小龙，阿祖，阿乐，阿豪……四年中无数的悲伤失意时刻，都有兄弟们的陪伴和支持。欲买桂花同载酒，终不似，少年游？时光流逝难挡，但祝我们永远拥有少年之心，每当相会时都能找回如这四年般的意气风发。

感谢遇到的所有人，一次次的相遇，成就了如今更好的自己。也要感谢自己，克服这一路上的困难，走在自己认为正确的道路上，希望自己永远乐观，永远自信，永远抬头挺胸。

终有一别，但来日方长。